面向 500 类细粒度图像分类的 CLIP-LoRA 系统

——以「降方差」而非「提容量」为核心的系统工程方案

团队： 明鉴 **赛题：** 算法挑战赛道 · 半决赛 **最终榜分：** **76.6137**（半决赛阶段最高分）

摘要

本作品在**只允许使用 OpenAI 官方 CLIP ViT-B/32 预训练权重**的约束下，构建了一套 500 类细粒度图像分类系统，最终榜分 **76.6137**。

技术路线并非"堆更强的模型"，而是先建立**可预测榜分的本地评估尺子**，再用它逐条筛选机制。系统本体由四个部分组成：LoRA 低秩微调（r=16，覆盖 q/k/v/out/fc1/fc2） + 抗噪损失组合（对称交叉熵 SCE + 类别均衡 + mixup） + 平坦极小优化（SAM + EMA + SWA） + 推理期 25 视图 TTA 与 Sinkhorn 概率校准。

本方案最重要的产出不是那 0.096 分的提升，而是**用实测把 11 条看似合理的技术路线逐条关闭**，并从中提炼出三条可复用的工程结论：

1. **本地尺子会系统性高估"分辨率类"增益**——同一份权重仅把推理分辨率从 560 抬到 672，尺子上 +0.17，榜上 **−0.42**；
2. **训练时的验证准确率与榜分已完全脱钩**——训练 val 最高的模型（0.8173）在尺子上反而最低；
3. **权重平均存在硬前提**——不同随机种子的模型落在不同损失盆地，直接平均导致 **−3.62pp** 的灾难性下降。

在这三条结论的约束下，唯一被证实为正、且可复现的增益来自**降方差**：把 TTA 视图从 15 个扩到 25 个（权重完全不变），榜分 **+0.096**。

一、赛题理解与问题定义

1.1 任务

给定 500 个视觉类别的带噪标签训练集，对 49,857 张测试图输出类别预测，提交格式为 `文件名，类别id` 的 CSV。评分指标为分类准确率，取半决赛阶段排行榜最高分。

1.2 硬约束

约束	内容
预训练权重	**仅允许 OpenAI 官方 CLIP ViT-B/32**，不得使用其他预训练模型或额外数据
提交端	**禁止集成**（判据是提交文件是否聚合多个模型）
数据	测试集不得参与训练

1.3 三个真实难点

1. **500 类细粒度**：类间差异小于类内差异，纯零样本 CLIP 不足以区分。

2. **训练集与测试集不同源**：本地留出集与训练集同源（同批 500×500 图），而官方测试集来自另一来源。这一点后来成为我们最关键的判据修正依据。
3. **标签噪声与类别不均衡**：直接影响上限，而非仅仅影响收敛。

二、数据与评估集

项	规模
训练集	**90,152 张 / 500 类**
测试集	**49,857 张**（扁平目录，文件名即提交 ID）
本地评估集（"尺子"）	**4,620 张**（`val_ratio=0.05`、`per_class=8` 分层留出）

2.1 数据清洗

- **pHash 近似重复清洗**：删除训练集内近似重复图，避免同图跨训练/留出集泄漏（该项在早期阶段带来 **+0.42pp**）。
- **软冲突组**：对标签冲突组构建软目标（组内不同标签均分），共 773 组、训练集命中 1,552 张，权重叠加后参与损失。
- **类别均衡权重**：`use_cl=True`，按类频的倒数加权，抑制长尾类被淹没。

2.2 关于"真全量"

冠军权重 `fd560v2` 使用 `val_ratio=0.0`，即**不按比例划留出集**；但 `val_per_class=1` 仍要求**每类至少留 1 张**做训练监控。实际划分（取自训练日志）：

```
[data] 全量 90152 张 / 500 类
[data] 训练 89652 / 验证 500（验证每类至少 1 张）
```

即**训练用 89,652 张，监控留出 500 张**（`best_val_acc=0.798` 是在这 500 张上得到的）。

这条取舍的代价是：**该模型无法再用本地 4,620 张尺子评估**（尺子与训练集同源，而模型已见过其中绝大部分），只能靠榜分反馈。这是明确的取舍——**用可测量性换绝对性能**。

三、方法

3.1 总体架构

```
图像 ─┬─ CLIP ViT-B/32 视觉塔（官方权重，注入 LoRA 旁路，仅最后 4 层解冻）
      │
      ├─ 池化特征（512 维）── 分类头 512→1024→GELU→500 ＋ 可学习 logit_scale
      │
      └─ 推理期：25 视图 TTA → 概率平均 → Sinkhorn 校准 → 提交
```

3.2 LoRA 低秩微调

参数	值
秩 r	**16**
作用模块	**q, k, v, out, fc1, fc2**（注意层 + MLP 全覆盖）
位置	**仅视觉塔**（文本塔冻结，本任务不需要）
可训练比例	约 21.9%（含解冻层与分类头）

选择 r=16 而非更大秩，是因为**秩加倍（r=32）在本栈上实测 −1.41pp**——在已经堆了多重正则的栈上，增加可训练容量是负向的。

3.3 分类头与温度

`Linear(512→1024) → GELU → Linear(1024→500)`，配一个**可学习** `logit_scale`（初值 100）。可学习温度的作用是让模型自行决定 softmax 的锐度，与后续 Sinkhorn 校准配合时更稳定。

3.4 抗噪损失组合

组件	配置	作用
对称交叉熵 SCE	α=0.1, β=0.05	对标签噪声鲁棒（SCE 对过自信样本降权）
类别均衡权重	`use_cl=True`	长尾类加权
mixup	0.2	平滑决策边界

剂量不可加：把 SCE 的 α 从 0.1 提到 0.3（3 倍剂量）后，尺子分从 81.97 掉到 **80.71（−1.26）**——抗噪剂量已在最优附近，加大反而伤。

3.5 知识蒸馏

以 **3 个教师模型**（不同分辨率/不同种子的强模型）的预测概率按 **T=3** 软化后平均，作为软目标；`kd_lambda=0.3`、`kd_topk=32`。软目标覆盖 85,532 张训练图（占全部 90,152 的 94.9%）。

3.6 平坦极小优化

组件	配置	说明
SAM	ρ=0.05	每步两次前向求平坦极小；**强制关闭 AMP 走 fp32**，代价是单步耗时约 2.7 倍（12 轮 × 1,867 步，约 23.5 分钟/轮）
EMA	decay=0.999，从第 1 轮起	跟踪 215 个张量（约 122 MB fp32），抑制后期抖动
SWA	从第 5 轮起，8 个 epoch 平均	训练结束时评估：**SWA 权重 val 0.7900，选优权重 val 0.7980 @ep11**；最终保存的是**选优权重**（与权重文件内记录的 `best_ep=11` / `best_val_acc=0.798` 一致）

3.7 部分解冻

`unfreeze_last=4`：只解冻视觉塔最后 4/12 层，骨干学习率取主学习率的 0.1 倍（`backbone_lr_mult=0.1`）。**全解冻（12 层）经两次独立实证实为负向**（见 §4.4）。

3.8 推理期 25 视图 TTA

视图集合由多裁剪比例（`rc0`–`rc15`）、短边缩放（`zoom240`–`zoom336`）、翻转（`flip`）、方形拉伸（`square`）与基准视图组合而成，共 **25 个视图**，在**概率层面**算术平均。

关键点：**视图扩张不改变任何权重，只降低预测方差**。这也是本方案中唯一被榜分证实为正的改动。

3.9 Sinkhorn 概率校准

对 25 视图平均后的概率矩阵做 Sinkhorn 归一化，目标为**类别分布均匀**，迭代 15 次。

校准强度用"目标类计数标准差 SD"控制：**SD≈14.5 为最优带**，健康带为 13–16。过度校正（SD 7.23）会掉 1.66pp，校正不足则几乎无效。本提交包实测 **SD=15.26**。

四、实验与结果

4.1 评估口径（本方案的基础设施）

我们没有直接靠提交次数试错，而是先建立了一把**本地尺子**：在固定 4,620 张分层留出集上跑 15 视图 TTA，得到与榜分强相关的本地分。

锚点	尺子分	榜分
px560	81.99	76.30
fd560（真全量）	——	76.44
fd560v2（冠军）	——	76.52
本提交（fd560v2 + 25 视图）	——	**76.6137**

由此得到经验偏移：**榜分 ≈ 尺子分 − 5.69**。这把尺子让"改一个机制、量一次"的迭代成本从"消耗一次提交"降到"跑一次本地评估"。

4.2 主结果

配置	视图数	校准 SD	榜分
fd560v2（原有最好）	15	14.44	76.5173
fd560v2 + 25 视图（本提交）	**25**	**15.26**	**76.6137**
相对提升	+10 视图	—	**+0.096**

仅翻转了 3.47% 的预测（约 1,730 / 49,857 条），改动幅度与增益同量级，可解释、可复现。

4.3 消融：11 个机制的实测判决

基准：`runA`（640 / 解冻 4 层 / 16 轮 / SAM / val 0.05）= 尺子 **81.97**。

#	机制	实测	相对基准	判决
1	全解冻 12 层（容量）@560	尺子 81.36	**−0.61**	关闭（复赛另测 −1.0，两次独立）

#	机制	实测	相对基准	判决
2	SCE 剂量 α=0.3（3×）	尺子 80.71	**−1.26**	关闭
3	LoRA 缩放 ×1.1	尺子 81.75	**−0.22**	关闭
4	model soup（两种子权重平均）	尺子 **78.35**	**−3.62**	关闭（盆地不同）
5	MixStyle p=0.5	同步第 3 轮 val 落后 1.3pp	——	中途终止
6	多层特征融合 3 层	尺子 79.87	**−2.10**	关闭
7	672 分辨率训练	尺子 81.84	**−0.13**	关闭
8	672 训练模型再 FixRes 到 704	尺子 81.62	**−0.35**	关闭
9	**FixRes 560→672（冠军上）**	**榜 76.0959**	**−0.42**	关闭
10	cutmix + CRT + 463 条伪标签修正	**榜 74.86 / 75.16**	**−1.66 / −1.36**	关闭
11	换随机种子	尺子 82.01	+0.04	无实质增益
✅	**TTA 视图 15 → 25**	**榜 +0.096**	**+0.096**	**唯一为正**

4.4 关键发现一：尺子会系统性高估"分辨率类"增益

改动	尺子	榜分
runA 640 → 672 推理	81.97 → **82.14（+0.17）**	——
冠军 560 → 672 推理	（真全量，无法上尺子）	76.52 → **76.10（−0.42）**

原因：4,620 张留出集与训练集**同源**（同批 500×500 图），官方测试集**异源**。分辨率上采样产生的伪影在"同源"数据上几乎无害，在"异源"数据上被显著放大。

推论：分辨率类收益必须按 1/3 折算，或直接不做；只有**降方差**类改动（更多视图、更稳的校准）才真正兑现到榜分。**我们的最终提交正是据此从"提分辨率"转向"加视图"。**

4.5 关键发现二：训练 val 与榜分已脱钩

模型	训练 val	尺子
r672full（672 训练）	**0.8173（最高）**	81.84（最低）
runA（640 训练）	0.8156	81.97
seed2（640，换种子）	0.8128	82.01

训练 val 最高的模型，尺子反而最低。**结论：只认尺子，不认训练 val。**

4.6 关键发现三：权重平均有硬前提

两个独立训练、各自尺子 82.14 / 82.01 的模型，直接平均权重后掉到 **78.35（−3.62）**。

原因：换随机种子后两模型落在**不同的损失盆地**，直接平均落在盆壁上的高损失区域。**权重平均（model soup）必须使用同一条训练轨迹上的多个 checkpoint**，不能跨 seed。

4.7 负结果的主动披露

除上述 11 条，更早阶段我们还关闭了：秩加倍 r32（−1.41）、VPT（−1.27）、cosine margin（−2.0）、标签调整 la（全负）、强增广（负）、类均衡重采样（负）、ASAM（负）。

这些负结果本身是本作品的方法论产出：在已有 13 个正则机制的栈上，任何新机制的残余空间远小于文献报告的"从零加"增益。11 次尝试 10 次为负，就是这个"强基线折扣"的实证。完整清单见随附《负结果与判死方法》。

五、复现

项	内容
环境镜像	`python:3.12-slim` + torch 2.6.0+cu124 / transformers 5.20.2 / numpy 2.1.3 / pandas 3.1.0 / scipy 1.18.1 / pillow 11.0.0（镜像**只含环境**，不含数据/模型/代码）
数据/模型/代码	**全部由宿主机挂载**进容器，符合组委会要求
唯一权重	`fd560v2_best.pt`，md5 `4d80f64f947e46d0b112e5d93793edb8`
复现命令	`predict_tta.py`（25 视图）→ `calib_sinkhorn_apply.py`（iters=15）→ `check_submission.py`
预期产物	`pred_results.csv` md5 **`506d1919f3654b73e2ebbf9c8530ac90`**，49,857 行，500 类全覆盖
单卡耗时	25 视图 TTA ≈ 75 分钟（A100 / 4090）

> **关于 md5 的说明（实测）**：同一张 GPU 上跑两次，`probs.npy` 的 md5 完全相同（bit 级确定）。换用不同 GPU 型号时，fp16/cuDNN 实现不同会带来数值差异：逐元素概率差中位数 1.2e-06， 但**每图最大偏移中位数 1.6e-02**，足以翻转"几乎平局"的样本——抽检 2,001 张中 89 张不同（一致率 95.6%）， 且翻转**全部**落在 top1−top2 间距 <0.2 的图上（间距 >0.2 的零翻转）。 此情形下只要行数为 49,857、覆盖 500 类即属正常，对准确率影响约 **±0.2pp**。

详见随附《复现说明》。

六、结论与局限

结论

1. 在"只用官方 CLIP 权重"的约束下，**LoRA 微调 + 抗噪损失 + 平坦极小 + 降方差推理** 是一个稳定、可复现、可解释的组合，在本赛题上取得 76.6137。

2. 真正的工程价值在于**建立了可预测榜分的本地尺子**，并据此把 11 条技术路线快速关闭，避免把提交次数浪费在探索上。
3. 最终那 0.096 的提升来自"多平均 10 个视图"，而不是任何模型结构的改动——这与本栈已高度饱和的事实一致。

局限（如实说明）

1. **增益量级小**：+0.096 属于可复现但幅度有限的改进；本方案的分数上限受限于 CLIP ViT-B/32 的预训练质量与 500 类细粒度任务的固有难度。
2. **尺子存在系统性偏差**：它高估分辨率类收益（已量化）；在"同源/异源"不同的数据分布上，它在设计上就不可靠。
3. **多层特征融合未被有效验证**：我们只跑通 8 轮的版本（尺子 79.87），无法区分是"机制本身无效"还是"训练轮数不足"——这是本方案未解决的开放问题。
4. **真全量模型不可测量**：冠军权重使用全量训练，因此无法用本地尺子评估，只能靠榜分反馈，这限制了后续迭代的可控性。

附：随附材料

- `docs/技术方案.pdf`（本文）
- `模型目录/`：`fd560v2_best.pt` + 模型说明（含 md5 与推理入口）
- `代码目录/`：训练与推理代码、配置、依赖锁、数据说明
- `pred_results.csv`：榜分 76.6137 对应的预测文件
- `docs/复现说明.md` + `Dockerfile` + `requirements.image.txt`
- `docs/负结果与判死方法.md`：11 条关闭路线的完整实测依据